

DS Mini Project · DAY 1

EDA 기반 모델링 전략

초기 100사이클 데이터로 배터리 Cycle Life 예측

울산캠퍼스 4반 · 정예지

목차

1 문제 정의 및 데이터 구성

Target 정의 · 회귀 선택 근거 · 전처리 파이프라인 · 방전 곡선 정렬

2 EDA

핵심 변수 분포 탐색 · 통계량 확인 및 해석 · Feature Engineering & Selection

3 EDA → 전략 연결

EDA 관측별 시사점 도출 및 전략 반영 내역

4 모델링 전략

Feature 설계 논리 · 모델 선택 논리 · 검증 및 평가 계획

초기 100사이클 기록으로 전체 수명을 예측하는 회귀 문제로 정의

예측 문제

구분	정의
목표	배터리의 초기 100사이클 측정 기록만으로 전체 수명을 예측함
Y (Target)	cycle_life : EOL 도달까지의 사이클 수
X (Feature)	Cycle 1~100 구간에서 계산한 방전 곡선 변화, 충전 조건, 용량, 온도, 내부 저항
학습 단위	배터리 1개 = 학습 사례 1개
활용	수명 종료까지 시험하지 않고 초기 단계에서 단수명 셀을 선별함


회귀 vs 분류 판단 (임계값 550 사이클)

Batch	Short <550	Long ≥550	전부 Long 예측 시 정확도
Batch 1 (학습)	1	45	97.8%
Batch 2 (Test)	30	9	23.1%
Batch 3 (추가 Test)	1	43	97.7%

- 학습 배치의 단수명 셀이 1개에 불과하여 분류 시 단수명 클래스의 학습·검증이 불가능함
- 모든 셀을 Long으로 예측해도 학습 정확도가 97.8%로 산출되어 성능 비교가 무의미함

시사점 회귀 문제(Target = cycle_life)로 정의하고 평가 지표는 MAPE를 사용함

실제 예측 시점과 동일하게 Cycle 1~100 데이터만 사용하는 전처리 파이프라인



단계 구분

단계	정의	예시 (IR)
전처리	원본을 분석 가능한 상태로 변환	$IR \leq 0 \rightarrow \text{결측}$
피처 생성	셀 단위 설명변수 계산	Cycle 1~100 유효 IR의 중앙값
피처 선택	모델에 투입할 변수 결정	IR은 M4 세트에서만 사용
모델 Pipeline	학습 fold 안에서 fit하는 변환	IR 결측 셀 중앙값 대치


설계 원칙

- **시점 우선** : 관측 구간을 가장 먼저 제한하여 이후 모든 판단에서 미래 정보를 차단함
- **삭제보다 표시** : 오류로 확정할 수 없는 값은 유지하고, 제외 시 결과는 대안 세트로 별도 비교함
- **통계량 학습은 fold 내부** : 대치값·스케일 파라미터를 전체 데이터에서 계산하지 않음

시사점 미래 정보를 차단하고 물리적으로 유효한 초기 구간 데이터만 피처 생성 단계로 전달함

분석 대상과 관측 구간을 확정하고 무효 측정값을 처리

① 분석 대상 확정



cycle_life는 지도학습의 정답이므로 없는 셀은 학습·평가에 사용할 수 없음. 제외 10셀 = B2 특수 프로토콜(VarCharge·SLOWCYCLE) 8셀, B3 2셀

② 관측 구간 제한


사용 : Cycle 1 — 100

사용 금지 : ~~Cycle 101 — EOL~~

Knee point(배치별 중앙값 기준 수명의 75.6~79.3% 지점)는 미래 사이클이 필요하므로 모델 입력에서 제외하고 설명용으로만 사용함

③ 측정값 유효성 처리

검사	판단	처리	후속 연결
B1 Cycle 1의 모든 채널이 0 (46행)	초기 용량 0이 아닌 초기화 기록	해당 행 결측	초기 용량을 Cycle 2~6 중앙값 으로 정의
$IR \leq 0$ (B2 600행)	유효 저항값이 아님	해당 채널 결측	B2 6셀은 유효 IR이 없어 셀 단위 결측 → fold 내부 중앙값 대체
이동 중앙값 대비 2% 급변 (10행)	오류 확정 근거 없음 (2%는 검토용 잠정 기준)	원본 유지, 플래그	급변 제외 용량 피처를 대안 세트 로 비교




초기 100사이클 방전 용량 (빈 원 = 2% 급변 후보, 삭제하지 않음)

서로 다른 측정 전압축을 공통화하여 ΔQ 비교가 가능하도록 정렬

필요한 이유

- 셀·사이클마다 전압 측정 지점이 달라 Q100(V) – Q10(V)를 같은 전압에서 직접 계산할 수 없음



항목	설정
전압 구간	2.0 ~ 3.5 V
격자 점 수	300점
보간 방식	선형 보간 (np.interp)
외삽	사용하지 않음 (범위 미달 시 무효)


곡선 품질 기준 (하나라도 실패 시 ΔQ 무효)

#	검사 항목	기준
1	곡선 존재	전압·용량 배열 존재, 길이 일치, 3점 이상
2	유효 측정점	유한값 비율 ≥ 95%
3	전압 정렬	정렬 후 중복 전압 없음
4	범위 확보	관측 전압이 2.0~3.5V 전체 포함
5	공백	공통 구간 내 인접 점 간격 ≤ 0.05V
6	계산 가능	ΔQ 분산 > 0 (log10 가능)

129셀 모두 6개 기준을 통과하여 ΔQ 결측 셀 없음. 기준은 Test 정답에 맞춰 조정하지 않음

시사점 공통 전압축 정렬은 Core Feature `log10_dq_var` 의 기반이므로, 관측되지 않은 전압 구간을 만들어내지 않도록 **외삽을 금지함**

학습 배치와 평가 배치의 수명 분포가 크게 다름




Batch	평균	중앙값	범위	<500	B1 범위 밖
B1	844.7	858.5	534-1,227	0.0%	-
B2	565.7	472.0	392-1,186	71.8%	76.9%
B3	1,059.7	1,005.5	541-1,935	0.0%	20.5%

- Batch 2의 중앙값은 472로 Batch 1 대비 약 45% 낮으며, 셀의 71.8%가 500사이클 미만임
- Batch 2 셀의 76.9%가 학습 배치 수명 범위(534~1,227) 밖에 위치하여 외삽 예측이 요구됨
- Batch 3는 반대로 장수명 방향(최대 1,935)으로 분포가 이동함

시사점 학습-평가 배치 간 Target 분포 차이가 커 **Batch 1 내부 검증 성능을 최종 성능으로 간주할 수 없음**. 외삽 가능 여부와 단수명 셀의 과대 예측이 핵심 평가 기준이 됨

Batch별 수명 분포 (공통 bin·축, 점선 = 중앙값)

초기 총용량만으로는 장·단수명 셀을 구분하기 어려움




상단: 전체 열화 곡선(점선 = Cycle 100) / 하단: 초기 100사이클 확대, 색상 = 실제 수명

변수 (Spearman ρ)	통합	B1	B2	B3
초기 용량 <code>qd_initial_median</code>	-0.523	+0.075	+0.117	+0.136
초기 기울기 <code>qd_slope_10_100</code>	-0.196	+0.586	-0.220	+0.132

- 수명 후반에 급격한 용량 하락(knee)이 나타나나, Cycle 100 이전에는 장·단수명 셀의 상대 용량 곡선이 거의 겹침
- 초기 용량의 통합 상관(-0.523)은 배치 내부에서 0.08~0.14로 약화되어 배치 간 차이에 의한 효과로 판단됨
- 초기 기울기는 배치별로 상관 부호가 달라 일관된 신호로 보기 어려움

시사점 수명 차이는 초기 총용량 수준에서 드러나지 않으므로 방전 곡선 형태의 변화를 탐색해야 함

방전 곡선 변화(ΔQ)는 세 배치 모두에서 수명과 일관된 관계를 보임



$\Delta Q(V) = Q100(V) - Q10(V)$, 배치 내부 수명 하위 1/3(실선) vs 상위 1/3(점선), 띠 = 셀 25~75% 범위


변수 (Spearman ρ)	통합	B1	B2	B3
<code>log10_dq_var</code>	-0.892	-0.871	-0.709	-0.797
<code>dq_min</code>	+0.884	+0.853	+0.657	+0.776

`log10_dq_var` ↔ `dq_min` 상관 $r = -0.939$ 로 동일 정보를 표현함

- 세 배치 모두 단수명 그룹의 ΔQ 곡선이 0에서 더 크게 벗어남
- ΔQ 분산(log10)은 세 배치 모두 -0.71 ~ -0.87의 같은 방향 상관을 보이며, 후보 피쳐 중 상관이 가장 강함
- 총용량이 같아도 전압 구간별 용량 변화에 열화 신호가 반영됨을 확인함

시사점 `log10_dq_var` 를 **Core Feature**로 고정하고, 중복 변수 `dq_min` 은 제외함

로그 변환으로 ΔQ -수명 관계의 선형성을 확보



Shaded x-span = Batch 1 feature range. One dot = one cell. Association is not validated prediction accuracy.

log10 ΔQ 분산 vs 수명 (음영 = Batch 1 피쳐 범위)

ΔQ 분산의 로그 변환

- ΔQ 분산은 셀 간 수십 배 차이가 나는 왜도 큰 분포임
- log10 변환 후 수명과 거의 직선 관계를 보임 (통합 Pearson $r = -0.886$)


Target 표현 비교 : Pearson r (log10_dq_var 기준)

Batch	cycle_life	log10(cycle_life)	변화
B1	-0.886	-0.868	유사
B2	-0.902	-0.918	선형성 증가
B3	-0.701	-0.761	선형성 증가

- 평가 배치에서 로그 수명이 ΔQ 와 더 강한 선형 관계를 보임
- Batch 2 셀의 28.2%는 ΔQ 값 자체도 학습 범위 밖에 위치함

시사점 원 수명과 로그 수명 두 Target을 모두 학습하고, 원 사이클 단위로 복원하여 MAPE로 비교함

충전 속도는 수명과 관련되나 배치별로 영향의 크기가 다름



Peak current does not describe the full charge policy. Inspect C1 / switch SOC / C2 and sample counts in the table; no causal conclusion is drawn.

최대 충전 C-rate vs 수명 (▲ = newstructure 태그)


변수 (Spearman ρ)	B1	B2	B3
peak_c_rate	-0.483	-0.359	-0.607
switch_soc	+0.185	+0.288	+0.443
chargetime_median_100	+0.641	-0.811	+0.265

Batch 2 동일 정책 4.8C(80%)-4.8C		평균 수명
태그 없음		483.6
newstructure 태그		871.7

- 최대 C-rate는 세 배치 모두 음의 상관을 보여 고속 충전 시 수명이 짧아지는 경향이 일관됨
- 충전시간은 배치 간 상관 부호가 역전되며, 0→80% 근사 충전시간이 B1 8.9~13.3분인 반면 B2·B3는 약 10분으로 고정되어 변동이 없음
- 동일 충전 정책에서도 수명이 약 1.8배 차이 나므로 충전 정책만으로 수명을 설명할 수 없음

시사점 충전 조건은 ΔQ에 대한 **추가 효과**(M2)로 검증함. 평가 배치의 충전시간 변동 부족은 일 반화 위험에 대한 진단으로 기록함

방향이 일관된 피처는 ΔQ와 충전 조건으로 한정됨



NA = constant, insufficient, or missing measurements. Cell counts differ by feature. Test labels are not used for feature selection.

주요 후보 피처의 Spearman 상관 (통합 / 배치 내부)

피처	방향 일관성	B2 범위 밖
log10_dq_var	일관 (- / - / -)	28.2%
peak_c_rate	일관 (- / - / -)	0.0%
switch_soc	일관 (+ / + / +)	5.1%
qd_initial_median	배치 내부 ≈ 0	51.3%
qd_slope_10_100	불일치 (+ / - / +)	59.0%
tavg_median_100	불일치 (- / + / +)	20.5%
ir_median_100	불일치 (+ / - / +)	12.1%

- 세 배치에서 방향이 일관된 피처는 ΔQ와 충전 조건(최대 C-rate, 전환 SOC)뿐임
- 용량·온도·IR 피처는 방향이 불일치하고 평가 배치 범위 이탈이 큼
- IR은 Batch 2에서 15.4% 결측(39셀 중 33셀만 유효)임

Batch 2·3 상관은 사후 진단이며 피처 제외 근거로 사용하지 않음. 범위 이탈은 입력값(X)만으로 계산함

시사점 피처를 일괄 투입하지 않고 **일관성이 높은 순서로 단계적으로 추가**하여 효과를 분리 검증함

Cycle 1~100 정보만으로 4개 그룹 16개 후보 피처를 생성

그룹	대표 변수	생성 방법	설계 근거
① 방전 곡선 변화 (Core)	log10_dq_var	정렬된 곡선에서 $\Delta Q(V) = Q_{100}(V) - Q_{10}(V) \rightarrow$ 전압 방향 분산 $\rightarrow \log_{10}$	초기 총용량은 같아도 곡선 형태 변화에 열화 신호가 반영된다는 가설
② 충전 조건	peak_c_rate switch_soc	정책 문자열 예: 6C(40%)-3C를 C1·전환 SOC·C2로 분해, 최대 C-rate 산출	고속 충전 시 수명 단축이라는 도메인 지식 반영
③ 초기 용량	qd_initial_median qd_slope_10_100	Cycle 2~6 용량 중앙값 (Cycle 1 초기화 기록 회피) / Cycle 10~100 Theil-Sen 기울기	이상치에 강건한 통계량으로 초기 수준·추세 표현
④ 상태 변수	tavg_median_100 ir_median_100	Cycle 1~100 유효값의 중앙값 (유효값이 없으면 셀 단위 결측 유지)	온도·저항이 보조 단서가 되는지 확인



- 모든 피처는 Cycle 1~100 정보만으로 계산하여 실제 운영 시점에서 산출 가능하도록 설계함
 - log10 변환은 셀 간 수십 배 차이 나는 분산의 왜도를 줄이기 위해 적용함
- 총 16개 후보 피처를 생성하고, 이상 후보를 제외한 대안 용량 피처를 별도로 보존함
 - 타깃·셀 ID·배치·knee point는 모델 입력에서 명시적으로 제외함

중복 정보와 일반화가 불가능한 변수를 제거하여 7개 피처로 축소

중복 정보 제거 (Batch 1 Train, $|r| \geq 0.8$)

변수 쌍	r	선택
log10_dq_var ↔ dq_min	-0.939	log10_dq_var
c_rate_1 ↔ peak_c_rate	1.000	peak_c_rate
peak_c_rate ↔ c_rate_gap	0.897	peak_c_rate
t80_min ↔ chargetime_median_100 ↔ effective_c_rate_80	$ r \geq 0.99$	기본 세트 제외, 대체 후보로 보존
log10_dq_var ↔ t80_min / chargetime	-0.82 / -0.81	Core와 정보 중복
qd_change ↔ qd_ratio ↔ qd_slope	≥ 0.966	qd_slope_10_100

다중공선성 (VIF, Train 36셀)

피처	VIF
log10_dq_var	3.49
peak_c_rate	9.45
switch_soc	6.53
qd_initial_median	1.04
qd_slope_10_100	1.74

선택 결과 : 후보 16개 → 7개

- Core 1 : log10_dq_var
- 충전 조건 2 : peak_c_rate, switch_soc
- 보조 4 : qd_initial_median, qd_slope_10_100, tavg_median_100, ir_median_100

시사점 제외 판단은 Batch 1 Train 구간의 중복 정보만으로 수행하여 Test 정답이 선택에 개입하지 않도록 함. 잔존 공선성(VIF 9.45)은 **규제 모델**로 대응함

EDA에서 확인한 데이터 특성을 전략에 일대일로 반영

EDA 관측	시사점	전략 반영
학습 배치의 단수명(<550) 셀 1개	분류 클래스 학습 불가	회귀 문제로 정의
B2 IR 6셀 유효값 없음, 용량 급변 10행	결측·이상 후보 존재	fold 내부 대치, 급변 제외 대안 세트 비교
Batch 2의 76.9%가 학습 수명 범위 밖	외삽·분포 이동 대응 필요	선형 기준 모델, log Target 비교, 과대 예측 지표 추가
ΔQ 상관 $-0.71 \sim -0.87$, 세 배치 동일 방향	가장 안정적인 수명 신호	Core Feature 고정 (M1)
최대 C-rate 일관된 음의 상관, VIF 9.45	추가 정보 존재 + 공선성	M2 추가, Ridge 비교
동일 정책에서 수명 1.8배 차이	정책만으로 설명 불가	셀 상태(ΔQ)와 정책 결합
초기 용량 배치 내부 상관 ≈ 0 , 기울기 부호 역전	단독 신호 불안정	보조 피처(M3), Elastic Net 비교
충전시간 계열은 정책 파라미터로 계산되며 서로 $ r \geq 0.99$, ΔQ 와 $r \approx -0.82$ (Train)	충전 정책·Core와 정보 중복	기본 세트 제외, 대체 후보로 보존
온도·IR 방향 불일치	보조 정보 수준	M4에서만 추가 검증
상호작용 가능성 (C-rate $\times \Delta Q$)	비선형 관계 확인 필요	얇은 RF·제한된 Boosting 비교

Core Feature에 정보 그룹을 단계적으로 추가하는 M0~M4 구조

단계적 Feature Set

Set	입력 변수	검증 질문
M0	없음 (Train 수명 중앙값)	단순 기준 대비 개선되는가
M1	<code>log10_dq_var</code>	곡선 변화 단독 예측력은 어느 정도인가
M2	M1 + <code>peak_c_rate</code> , <code>switch_soc</code>	충전 조건이 추가 정보를 제공하는가
M3	M2 + <code>qd_initial_median</code> , <code>qd_slope_10_100</code>	초기 용량 수준·추세가 기여하는가
M4	M3 + <code>tavg_median_100</code> , <code>ir_median_100</code>	온도·저항 정보가 추가 이득을 주는가

설계 논리

- **신뢰도 순 추가** : 세 배치 방향 일관성이 높은 피처부터 투입하여 각 그룹의 기여를 분리함
- **중복 배제** : 동일 정보를 표현하는 변수는 대표 1개만 사용함
- **Target 2종** : `cycle_life`와 `log10(cycle_life)`를 각각 학습하고 원 단위로 복원하여 비교함
- **대안 비교** : 급변 후보를 제외한 용량 피처로 교체한 세트를 추가 비교함

시사점 Feature와 모델을 동시에 바꾸지 않음으로써 성능 향상이 어떤 정보에서 비롯되었는지 해석 가능하도록 설계함


선형 기준 모델에 규제·비선형 모델을 비교군으로 구성

후보 모델	알고리즘 특성	데이터 근거	역할
Linear Regression	계수 해석 가능, 학습 범위 밖 외삽 가능	ΔQ -수명 강한 단조 관계	기준 모델
Ridge	L2 규제로 상관 변수 계수 안정화	Train 36셀, VIF 9.45	주요 선형 후보
Elastic Net	L1 변수 축소 + L2 안정화	배치별 방향이 뒤집히는 피처 존재	불안정 피처 축소 검증
Random Forest (알게)	비선형·상호작용 포착, 예측이 학습 Target 범위에 제한됨	C-rate $\times$ ΔQ 상호작용 가능성, B2 76.9% 범위 밖	외삽 한계 확인용 비교군
XGBoost / LightGBM (제한)	이전 트리 오차를 순차 보완	비선형 비교, 소표본 과적합 위험	depth·학습률·트리 수 제한

딤러닝 미사용 근거

- 학습 표본이 배터리 36개로 대규모 파라미터 모델은 과적합 위험이 큼
- 핵심 정보가 단일 피처(log10_dq_var)로 압축되어 표현 학습의 이점이 작음
- 성능 병목은 모델 용량이 아닌 배치 간 분포 이동임
- ΔQ 변화량에 따른 수명 변화를 계수로 해석할 수 있어야 진단·교체 의사결정에 활용 가능함

Batch 1 내부 검증 후 Batch 2·3에서 일반화 성능을 평가



평가 지표

지표	확인 내용
MAPE (주 지표)	상대 오차, 과제 기준 지표
MAE	평균 오차 사이클 수
평균 부호 오차 / 과대 예측 비율	단수명 셀을 길게 예측하는 편향 여부

모델별 Pipeline (각 학습 fold 안에서 fit)

모델	Pipeline
Linear · Ridge · Elastic Net	Median Imputer → StandardScaler → 모델
Random Forest · Boosting	Median Imputer → 모델 (스케일링 불필요)

Leakage 방지

- 규제 강도가 변수 크기에 영향을 받으므로 선형 계열만 표준화함
- 동일 충전 정책 셀이 Train·Valid에 동시에 포함되는 영향을 Group CV로 진단함
- Test 성능이 낮은 셀을 사후 제외한 점수는 주 결과로 사용하지 않음

EDA

학습-평가 배치 간 수명 분포 차이가 크며(B2 76.9% 범위 밖), 초기 총용량은 구분력이 없는 반면 $\Delta Q(V)$ 변화량은 세 배치에서 일관된 상관 ($-0.71 \sim -0.87$)을 보임

EDA → 전략

단수명 셀 부족으로 회귀를 선택하고, ΔQ 를 Core Feature로 고정함. 방향 일관성과 범위 이탈 정도에 따라 나머지 피처를 단계적으로 배치함

모델링 전략

M0~M4 단계적 Feature Set × 선형·규제·트리 모델을 비교하고, Batch 1 내부 검증 후 Batch 2·3에서 MAPE와 예측 편향으로 일반화 성능을 평가함

ΔQ 중심의 단순·규제 선형 모델을 기준으로 두고, 비선형 모델은 추가 이득 여부를 확인하는 비교군으로 활용함.
핵심 과제는 모델 복잡도가 아닌 **Batch 2로의 일반화**임.